

Проект по курсу «Автоматическая обработка текстов»

Проект по курсу заключается в участии в одной из задач SemEval 2027 или в одном из перечисленных ниже долгосрочных соревнований Kaggle по обработке естественного языка. **Рекомендуется участие в SemEval 2027.** При желании команда студентов может выбрать и иной проект, но с обязательным согласованием и утверждением у преподавателя, ведущего курс. Проект выполняется в группах до 4-х человек. В ходе работы над проектом можно поучаствовать в одной или в нескольких дорожках выбранного соревнования.

SemEval 2027: <https://semeval.github.io/SemEval2027/tasks.html>

Альтернативные долгосрочные соревнования Kaggle:

1. LLM Classification Finetuning: <https://www.kaggle.com/competitions/llm-classification-finetuning>
2. Contradictory, My Dear Watson:
<https://www.kaggle.com/competitions/contradictory-my-dear-watson>
3. Natural Language Processing with Disaster Tweets:
<https://www.kaggle.com/competitions/nlp-getting-started>

1. Контрольная точка 1 (дата будет объявлена дополнительно)

К первой контрольной точке должен быть подготовлен отчет на 2-3 страницы. Отчет должен быть сдан одним из участников группы. Другие участники группы не обязаны сдавать отчет повторно, но подписать отчет должны все участники.

Регистрация на официальной платформе соревнования и получение доступа к данным может занять некоторое время (которое зависит от организаторов соревнования), поэтому необходимо пройти регистрацию заранее.

Отчет должен содержать краткое, но разумное описание работы. Рекомендуемая структура отчета:

[2 балла] Краткое описание задачи (переводить все описание соревнования не нужно) и формальную постановку задачи. Приведите описание входных и выходных данных, опишите входные данные и структуру целевого признака (является ли он бинарной меткой класса, последовательностью и т.д.). Опишите, как измеряется качество решения задачи. Проведите предварительный анализ данных, например, проверьте, сбалансированы ли классы, есть ли в данных опечатки или примеры некорректной разметки, можно ли часть задачи решить простыми правилами и т.д.

[2 балла] Краткий обзор литературы (научных статей и / или блогов), в которых описано решение похожей задачи. Не стоит ссылаться на тривиальные источники, например, статьи о word2vec или BERT, постарайтесь найти что-то более специфичное для вашей задачи. Проанализируйте 2-3 источника.

[2 балла] Опишите базовую архитектуру модели, которую вы собираетесь использовать, и объясните, почему вы будете использовать именно ее. Опишите, как вы собираетесь улучшать эту модель в будущем.

[4 балла] Результаты, которые вы получили с помощью базовой модели:

- a. Скриншот вашего submission на официальной платформе соревнования (например, CodaLab или Kaggle)
- b. Если лидерборд соревнования открыт, то скриншот лидерборда

Если организаторы соревнования предоставили baseline, то разработанное вами решение должно быть лучше этого baseline. Если организаторы не предоставили baseline, объясните, почему ваши результаты соответствуют ожидаемому baseline.

2. Контрольная точка 2 (дата будет объявлена дополнительно)

[1 балл] Опишите, на чем вы остановились во время KT1 и какие улучшения модели планировали сделать.

[4 балла] Опишите детально более продвинутую архитектуру модели, которую вы собираетесь использовать, и объясните, почему вы будете использовать именно ее. Почему она лучше базовой модели? Не забудьте про ablation study: некоторые компоненты модели могут и снижать качество, проверьте, не происходит ли это в вашем случае.

[4 балла] Результаты, которые вы получили с помощью продвинутой модели:

- a. Скриншот вашего submission на официальной платформе соревнования (например, CodaLab или Kaggle), на котором видно, что ваша модель лучше общего baseline и лучше вашего собственного baseline
- b. Если лидерборд соревнования открыт, то скриншот лидерборда

[1 балл] Подведите итоги. Каких результатов получилось достичь? Какие улучшения позволили повысить качество вашей модели? Получилось ли у вас превзойти остальных участников соревнования?