

Автоматическая обработка текста

Дата, время и формат экзамена будут объявлены дополнительно.

Темы:

1. Предобработка текста. Токенизация, лемматизация, стемминг, стоп-слова.
2. Векторное представление текста. Мешок слов, TF-IDF. Сходство текстов в векторном пространстве.
3. Эмбединги. Символьные эмбединги, эмбединги слов, предложений, документов. Контекстуализированные и неконтекстуализированные эмбединги.
4. Языковая модель: определение, оценка качества. Классические языковые модели: примеры.
5. Языковая модель: определение, оценка качества. Нейросетевые языковые модели: примеры.
6. Моделирование последовательностей: типы, примеры задач, примеры подходов.
7. Классификация текстов. Постановка задачи, примеры подходов.
8. Рекуррентные нейронные сети: RNN, GRU, LSTM, Mamba. Основные принципы, примеры применения для анализа текстов.
9. Сверточные и графовые нейронные сети. Основные принципы, примеры применения для анализа текстов.
10. Архитектура «трансформер». Основные принципы, примеры применения для анализа текстов.
11. BERT и модели семейства BERT. Основные принципы. Обучение и дообучение с помощью BERT.
12. Современные LLM. Примеры моделей. Основные типы и параметры моделей. Основные техники, повышающие эффективность обучения и инференса моделей.
13. Современные LLM. Основные этапы подготовки данных и обучения моделей.
14. Суммаризация текстов. Экстрактивная и абстрактная суммаризация. Наборы данных, примеры подходов.
15. Симплификация текстов. Наборы данных, примеры подходов.
16. Лингвистические семантические ресурсы. Определение лингвистического ресурса, примеры ресурсов.
17. Генеративные языковые модели. Модели семейства GPT. Основные принципы, примеры применения для анализа текстов.
18. Промпт-инжиниринг. Zero-shot learning. Обучение на примерах. Определения, примеры применения для анализа текстов.